

Arquitectura del Comparador Regulatorio de Calidad de Gas Natural — Enagás

Documento técnico. Describe la arquitectura real del sistema (cotejada con el código), no el diseño teórico.


1. Filosofía: arquitectura híbrida "cero alucinaciones numéricas"

El sistema combina **dos mundos separados a propósito**:

- Mundo determinista** (código + ontología): la **única** fuente autorizada de cifras, límites, conversiones y comparaciones. Nunca improvisa un número.
- Mundo conversacional** (LLM): interpreta la pregunta en lenguaje natural y **redacta** la respuesta, pero tiene prohibido generar números — los obtiene llamando a herramientas deterministas.

La regla de oro está implementada en el flujo del chat: **determinista-primero, LLM-fallback**. Las preguntas estructuradas se resuelven con código determinista (sin riesgo de alucinación); solo las preguntas abiertas pasan al LLM, que está obligado a apoyarse en herramientas y en los documentos oficiales.

2. Mapa de componentes



3. La ontología — el corazón del sistema

Archivo: data/ontologia/ontologia_enagas.yaml

Es la **fuentes primaria de verdad**: la extracción verificada de los PDF oficiales. El motor determinista lee de aquí; el LLM nunca calcula ni inventa valores.

Estructura de nivel superior

Clave	Contenido
ontologia.fuentes_normativas	Las normas: id, organismo, publicación, url (enlace de cita), pdf (copia local), condiciones de referencia y notas.
parametros	Los 10 parámetros , cada uno con su bloque limites : por país.
unidades, flags	Catálogos auxiliares.

orquestador, motor_reglas, rag	Diseño/pipeline ideal (parte es aspiracional — ver §8).
--------------------------------	---

Cada límite (por parámetro y país) lleva

- valor o valor_min/valor_max, unidad, tipo_límite (rango / maximo / minimo)
- condiciones_referencia (temperatura de combustión / volumen, presión, notación)
- expresion_original (texto literal de la fuente)
- **estado_verificacion**: VERIFICADO O NO_VERIFICABLE_SIN_FUENTE (lo que no consta en fuente oficial **no se inventa**)
- cita: fuente (id de la norma) + artículo (sección y página)

Cobertura actual

- **10 parámetros**: Índice de Wobbe, PCS, densidad relativa, azufre total, H2S+COS, mercaptanos (RSH), O2, CO2, punto de rocío del agua, punto de rocío de hidrocarburos.
- **Jurisdicciones (12)**: España (base), Portugal, Francia, Italia, Alemania, Países Bajos, Bélgica, Noruega, Polonia, Dinamarca, Hungría y la UE (EN 16726).

El campo url de cada fuente es **fuentes_unicas**: lo usan a la vez la cita en pantalla (fuente_oficial.url_de) y el descargador de PDFs (actualizar_fuentes.py).

4. El motor determinista (de dónde salen las cifras)

Módulo	Función
fuentes_unicas.py	Capa de datos: lee la ontología y devuelve registros con cita completa (documento, organismo, artículo, página, URL, notación). Mapea nombre de país → código.
convertidor_unidades.py	Conversión de unidades (energía, temperatura, concentración) y la TABLA A1 literal de la ISO 13443 (factores entre condiciones de referencia). Todo cableado y verificado a mano.
condiciones_referencia.py	Mapea cada país a sus condiciones de referencia y delega el factor ISO 13443 en el convertidor.
motor_determinista.py	Capa heredada del Excel/CSV (ya retirado); hoy degrada con elegancia y solo hace de puente al RAG.

ISO 13443 (normalización a condiciones de España)

Para comparar PCS e Índice de Wobbe entre países con distinta temperatura de combustión/volumen, se aplican los **factores literales de la Tabla A.1** (gas real, base volumétrica), que viven en un único sitio (convertidor_unidades._TABLA_A1):

Conversión a España (0/0)	PCS	W	PCI
25/0 → 0/0 (Portugal, Alemania, Países Bajos, Bélgica, Noruega, Polonia, Dinamarca, Hungría)	1,0026	1,0128	1,0003
15/15 → 0/0 (Italia, UE)	1,0570	1,0169	1,0555
0/0 → 0/0 (España, Francia)	identidad (×1)		

Las concentraciones másicas (mg/m³) referidas a un volumen distinto de 0 °C (p. ej. Italia a 15 °C) se normalizan con el factor de gas ideal $(273,15+T)/273,15$. El % mol, lo adimensional y los puntos de rocío no dependen de la temperatura del volumen.

5. El router determinista (orquestración del chat)

```
api.py → _validate_measurement_gate(session_id, mensaje)
```

Antes de tocar el LLM, analiza el mensaje (parámetro + valor + unidad + países detectados) y resuelve **deterministamente** las preguntas estructuradas:

- 1. **Cumplimiento** — valor + unidad → cumple / no cumple.
- 2. **Límite/valor** — sin valor → muestra los límites (nunca "cumple"; sin valor no hay nada que cumplir).
- 3. **¿De qué reglamento sale?** — cita la fuente oficial.
- 4. **Intercambiabilidad** — solape de rangos frente a España.
- 5. **Más restrictivo / más amplio que España.**
- 6. **Comparación** España ↔ país (formato Enagás).
- 7. **Conversión a condiciones de España** (ISO 13443).

Si reconoce la intención → responde con modo: "determinista". Si **no** la reconoce → devuelve `None` y la petición pasa al LLM.

6. La capa LLM (preguntas abiertas)

```
api.py → responder_con_openai
```

- Modelo **OpenAI gpt-4o-mini** (configurable con la variable `OPENAI_MODEL`), **function-calling**, `temperature=0`, bucle de hasta 5 iteraciones de llamadas a herramientas.
- El `SYSTEM_PROMPT` (`src/llm/prompts.py`) le prohíbe inventar cifras, fija el ámbito (calidad de gas) y los países soportados.
- **Herramientas** que puede invocar (todas deterministas, salvo el RAG): `consultar_excel`, `evaluar_cumplimiento`, `convertir_unidades`, `convertir_condiciones_referencia` / `convertir_condiciones_iso13443`, y **buscar_pdfs** (RAG).
- **Tolerancia a fallos**: si OpenAI falla (clave inválida, red, límite) o no hay clave → cae al motor determinista (`_fallback_deterministic_response`). El chat nunca devuelve un error 500.

7. El RAG (preguntas abiertas, fundamentadas en los PDF)

```
agente_pdf.py + data/pdf_database.sqlite3
```

- Indexa los **PDF oficiales** de `data/raw/` (extracción con `pdfplumber`), troceados **por página**, en una base **SQLite**.
- `buscar_pdfs(query)` realiza una **búsqueda léxica** (SQLite `LIKE` sobre el texto normalizado + nombre/título del documento) y devuelve los fragmentos más relevantes con archivo, página y snippet.
- El LLM lo usa como herramienta para responder preguntas abiertas **citando** los documentos, sin inventar.

Importante: el RAG es **léxico** (palabra clave), no vectorial. No hay embeddings ni similitud semántica, aunque la sección rag de la ontología describa un diseño con Vector DB.

8. Spec vs. implementación (qué prometer y qué no)

El diseño / la ontología dice...	La realidad del código es...
RAG con Vector DB + similitud coseno + reranking	Búsqueda léxica SQLite <code>LIKE</code> (sin vectores)
Normalización "con pint"	<code>pint</code> no se importa en ningún módulo (dependencia muerta); las conversiones son tablas verificadas a mano
Respuesta del LLM en "7 secciones"	El prompt pide tabla + evidencias; las preguntas estructuradas las redacta el código , no el LLM
Historial de conversación	En memoria (<code>session_histories</code>); se pierde al reiniciar. No hay base de datos de conversaciones

9. Frontend, despliegue y mantenimiento

- `index.html` — SPA en **JavaScript puro** (sin framework). Render de Markdown con `marked` + saneado con `DOMPurify`. Identidad visual Enagás (azul + verde). Dos pestañas: *Consulta libre* (chat) y *Comparativa* (puntual + matriz/heatmap).
- `iniciar_chatbot.bat` — lanzador para los compañeros: **se auto-actualiza** (`git pull --ff-only`), **libera el puerto 8000** si quedó un servidor anterior y arranca `uvicorn`. La web se sirve **sin caché** (siempre la última versión).
- `actualizar_fuentes.py` — descarga los PDF desde el campo `url` de la ontología (fuente única); las fuentes HTML/sin PDF directo se marcan para descarga manual.

10. Stack tecnológico

Backend: Python · FastAPI · uvicorn · OpenAI SDK (gpt-4o-mini, function-calling) · pydantic · PyYAML (ontología) · pdfplumber (extracción PDF) · sqlite3 (índice RAG).

Frontend: HTML + JavaScript vanilla (marked, DOMPurify).

Endpoints HTTP: / (sirve la web) · /api/status · /api/chat · /api/parametros · /api/comparar · /api/matriz.

(En `requirements.txt` figuran `pandas`, `openpyxl` y `pint`, pero ya no se usan en el código.)

11. Flujo de una consulta (ejemplo)

Pregunta: "¿cumple 14 kWh/m³ de PCS en Francia?"

1. POST `/api/chat` → `_validate_measurement_gate`.
2. El router detecta: parámetro = PCS, valor = 14, unidad = kWh/m³, país = Francia, señal de cumplimiento.
3. Llama a `_evaluar_paises` → `fuentes_oficiales` lee el límite francés de PCS de la ontología (con su cita) → `convertor_unidades` normaliza unidades/condiciones si hace falta.
4. Compara 14 kWh/m³ con el rango francés → **cumple / no cumple**, con la cita oficial.
5. Devuelve la respuesta con `modo: "determinista"` — **sin pasar por el LLM**, sin posibilidad de inventar la cifra.

Una pregunta abierta como "¿qué es el índice de Wobbe?" no la reconoce el router → pasa al LLM, que la responde apoyándose en `buscar_pdfs` (RAG) y citando la fuente.